Data Analysis Tools and Practice(Using R)

2020.03.05

R语言数据对象II

北京大学 软件与微电子学院
School of Software and Microelectronics, Peking University

Huiping Sun(孙惠平)
sunhp@ss.pku.edu.cn

内容回顾

- 数据结构定义: *c(); matrix(); array(); data.frame(); factor(); list();*
- 数据结构访问: 下标; 下标向量; 逻辑向量; 负下标;
- 向量: :; *seq(); rep();*
- 算术运算符: +; -; *; /; **; ^; %%; %/%;
- 逻辑运算: >; <; >=; <=; ==; !==; !; |; &; ***isTRUE()***; *identical(); any(); all();*
- 属性函数: *length(); dim(); class(); names(); head(); tail();*
- 排序函数: *order(); sort(); sort.list(); which(); which.max(); which.min();*
- 运算函数: *max(); min(); range(); sum(); prod(); sqrt(); abs();*
- 类型函数: *is.numeric(); is.integer(); is.logical(); is.character(); as.xxxx();*
- 其余函数: *attach(); detach(); with(); $; t(); diag(); solve(); eigen();*

本节课程内容

- 矩阵运算
- 缺失值处理
- 类型转换
- 数据集合并
- 字符处理
- 日期和时间
- apply函数
- 统计函数

矩阵运算

t()	矩阵转置
det()	求矩阵行列式的值
crossprod(x,y)	x和y的内积(%*%)
tcrossprod(x,y)	x和y的外积(%o%), outer()
diag()	生成对角阵和矩阵取对角运算
solve()	解线性方程组，求矩阵的逆
eigen()	求矩阵的特征值和特征向量

矩阵运算例子

```
> A <- matrix(1:6, nrow = 2)
> A
     [,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6
> t(A)
     [,1] [,2]
[1,]    1    2
[2,]    3    4
[3,]    5    6
```

```
> x <- 1:5
> y <- 2*1:5
> x %*% y
     [,1]
[1,]  110
> crossprod(x,y)
     [,1]
[1,]  110
```

```
> x %o% y
     [,1] [,2] [,3] [,4] [,5]
[1,]    2    4    6    8   10
[2,]    4    8   12   16   20
[3,]    6   12   18   24   30
[4,]    8   16   24   32   40
[5,]   10   20   30   40   50
> tcrossprod(x,y)
     [,1] [,2] [,3] [,4] [,5]
[1,]    2    4    6    8   10
[2,]    4    8   12   16   20
[3,]    6   12   18   24   30
[4,]    8   16   24   32   40
[5,]   10   20   30   40   50
```

```
> det(matrix(1:4,ncol = 2))
[1] -2
```

```
> outer(x,y,FUN = "*")
     [,1] [,2] [,3] [,4] [,5]
[1,]    2    4    6    8   10
[2,]    4    8   12   16   20
[3,]    6   12   18   24   30
[4,]    8   16   24   32   40
[5,]   10   20   30   40   50
```

矩阵运算例子

```
> A <- array(1:9,dim=c(3,3))
> B <- array(1:9,dim=c(3,3))
> C <- A * B
> C
     [,1] [,2] [,3]
[1,]    1   16   49
[2,]    4   25   64
[3,]    9   36   81

> D <- A %*% B
> D
     [,1] [,2] [,3]
[1,]   30   66  102
[2,]   36   81  126
[3,]   42   96  150
```

```
> M <- array(1:9, dim=c(3,3))
> M
     [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9
> diag(M)
[1] 1 5 9
```

```
> A <- t(array(c(1:8,10), dim = c(3,3)))
> b <- c(1,1,1)
> x <- solve(A,b)
> x
[1] -1.000000e+00  1.000000e+00  3.330669e-16
```

```
> B <- solve(A)
> B
           [,1]      [,2] [,3]
[1,] -0.6666667 -1.333333    1
[2,] -0.6666667  3.666667   -2
[3,]  1.0000000 -2.000000    1
```

```
> A
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
[3,]    7    8   10
```

```
> Sm <- crossprod(A,A)
> ev <- eigen(Sm)
> ev
$values
[1] 303.19533618   0.76590739   0.03875643

$vectors
           [,1]         [,2]       [,3]
[1,] -0.4646675  0.833286355  0.2995295
[2,] -0.5537546 -0.009499485 -0.8326258
[3,] -0.6909703 -0.552759994  0.4658502
```

缺失值的处理

表4-1　领导行为的性别差异

经理人	日　期	国　籍	性　别	年　龄	q1	q2	q3	q4	q5
1	10/24/08	US	M	32	5	4	5	5	5
2	10/28/08	US	F	45	3	5	2	5	5
3	10/01/08	UK	F	25	3	5	5	5	2
4	10/12/08	UK	M	39	3	3	4		
5	05/01/09	UK	F	99	2	2	1	2	1

- 例子见教材74页
- ***NA***
- ***is.na()***
- ***na.rm = TRUE***
- ***na.omit()***

```
> y <- c(1,2,3,NA)
> is.na(y)
[1] FALSE FALSE FALSE  TRUE
```

```
> sum(1:5, NA)
[1] NA
> sum(1:5, NA,na.rm = TRUE)
[1] 15
```

看：例子*4-3*和*4-4*

类型转换函数

表4-5　类型转换函数

判　　断	转　　换
is.numeric()	as.numeric()
is.character()	as.character()
is.vector()	as.vector()
is.matrix()	as.matrix()
is.data.frame()	as.data.frame()
is.factor()	as.factor()
is.logical()	as.logical()

- 见教材**78**页

看：例子**4-5**

数据集合并cbind()和rbind()

```
> x1 <- rbind(c(1,2),c(3,4))
> x1
     [,1] [,2]
[1,]    1    2
[2,]    3    4
> x2 <- 10 + x1
> x3 <- cbind(x1, x2)
> x3
     [,1] [,2] [,3] [,4]
[1,]    1    2   11   12
[2,]    3    4   13   14
> x4 <- rbind(x1,x2)
> x4
     [,1] [,2]
[1,]    1    2
[2,]    3    4
[3,]   11   12
[4,]   13   14
> cbind(1, x1)
     [,1] [,2] [,3]
[1,]    1    1    2
[2,]    1    3    4
```

字符函数

- 见教材**93**页

nchar()	计算x中的字符数
substr(s,start,stop)	提取或替换一个字符向量中的子串
strsplit(x,split)	在split处分割字符向量x中的元素
toupper(x), tolower()	大小写转换
paste(…, sep="")	连接字符串
grep(pattern,x,ignore.case=FALSE,fixed=FLASE)	搜索 ★
sub(pattern,replacement,x,ignore.case=FALSE,fixed=FLASE)	搜索替换 ★

paste()函数

```
> paste("My","Job")
[1] "My Job"
>
> labs <- paste("X",1:6, sep="")
> labs
[1] "X1" "X2" "X3" "X4" "X5" "X6"
>
> paste("Today is", date())
[1] "Today is Wed Mar  2 12:41:21 2016"
>
> paste(c("a","b"),collapse=".")
[1] "a.b"
```

日期函数和格式

- 见教材**76**页

日期函数	*as.Date(x, "input_format")*
%d	数字表示的日期（0-31）
%a, %A	星期名（缩写，非缩写）
%m	月份（0-12）
%b, %B	月份（缩写，非缩写）
%y, %Y	年份（两位，四位）
Sys.Date(), date(), difftime(), format()	

日期函数例子

```
> mydates <- as.Date(c("2007-06-22"))
> mydates
[1] "2007-06-22"
> mydates <- as.Date(c("2007-06-22"))
>
> strDates <- c("01/05/1965")
> dates <- as.Date(strDates, "%m/%d/%Y")
>
> Sys.Date()
[1] "2016-03-02"
> date()
[1] "Wed Mar  2 12:48:52 2016"
```

日期函数例子

```
> today <- Sys.Date()
> format(today, format = "%B %d %Y")
[1] "March 02 2016"
> format(today, format = "%A")
[1] "Wednesday"
>
> startdate <- as.Date("2004-02-13")
> enddate <- as.Date("2009-06-22")
> days <- enddate - startdate
>
> today <- Sys.Date()
> format(today, format = "%B %d %Y")
[1] "March 02 2016"
> dob <- as.Date("1956-10-10")
> format(dob, format = "%A")
[1] "Wednesday"
> difftime(today,dob, units="weeks")
Time difference of 3099 weeks
```

apply()函数

apply(x, MARGIN, FUN, ...)

```
> a <- matrix(1:6,nrow=2)
> a
     [,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6
> apply(a, 1,sum)
[1]  9 12
> apply(a,2,sum)
[1]  3  7 11
```

- 见教材**95**页

看：例子**5-5**和**5-6**

apply()函数

```
> mydata <- matrix(rnorm(30), nrow=6)
> mydata
           [,1]       [,2]       [,3]       [,4]        [,5]
[1,]  1.1039131 -0.6779796  0.09072753  0.6943354 -0.68360455
[2,] -1.2876154  0.1540778  1.41431948 -0.9622685  2.07486216
[3,] -0.4221483  0.3073955  0.36975022 -0.4124088  0.54614267
[4,] -0.5283792 -0.7510899 -1.58224514  1.1124982  0.24044145
[5,] -1.1322217  1.0616374  0.37744029  0.1879165 -0.03192165
[6,]  0.7633084  0.6153539  0.58158158  0.3485943  0.17747101
> apply(mydata, 1, mean)
[1]  0.10547839  0.27867512  0.07774626 -0.30175492  0.09257018  0.49726184
> apply(mydata, 2, mean)
[1] -0.2505238  0.1182325  0.2085957  0.1614445  0.3872318
> apply(mydata, 2, mean, trim=.4)
[1] -0.4752638  0.2307367  0.3735953  0.2682554  0.2089562
```

统计函数

- 见教材**87**页

mean(x), median(x)		平均数，中位数
sd(x), var(x)		标准差，方差
max(x), min(x)		最大值，最小值
range(x), sum(x)	★	值域，求和
quantile(x, prob)	★	求分位数
diff(x, lag=n)	★	滞后差分
scale(x, center=TRUE, scale=TRUE)	★	为数据对象x按列进行中心化和标准化
str(), summary()		

看：例子*5-1*

提问时间！

孙惠平

sunhp@ss.pku.edu.cn

练习

练习 - 0008

第四章、第五章

第五章-第七章

R Data II

练习 - 0009

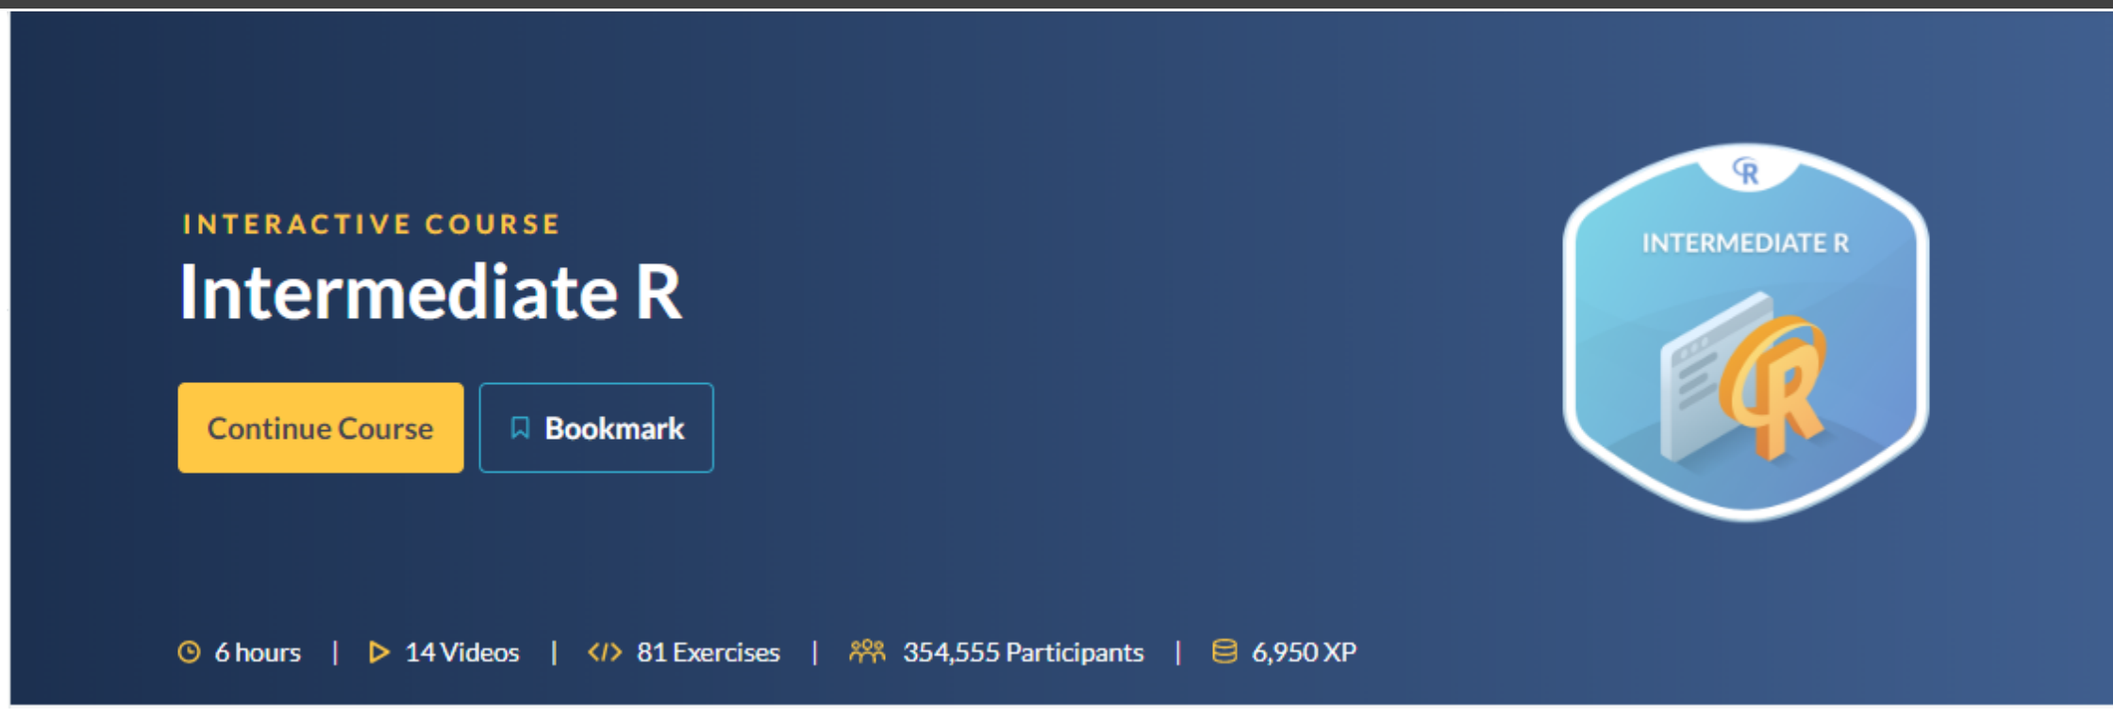

提交方式和上节课一样！

https://www.datacamp.com/courses

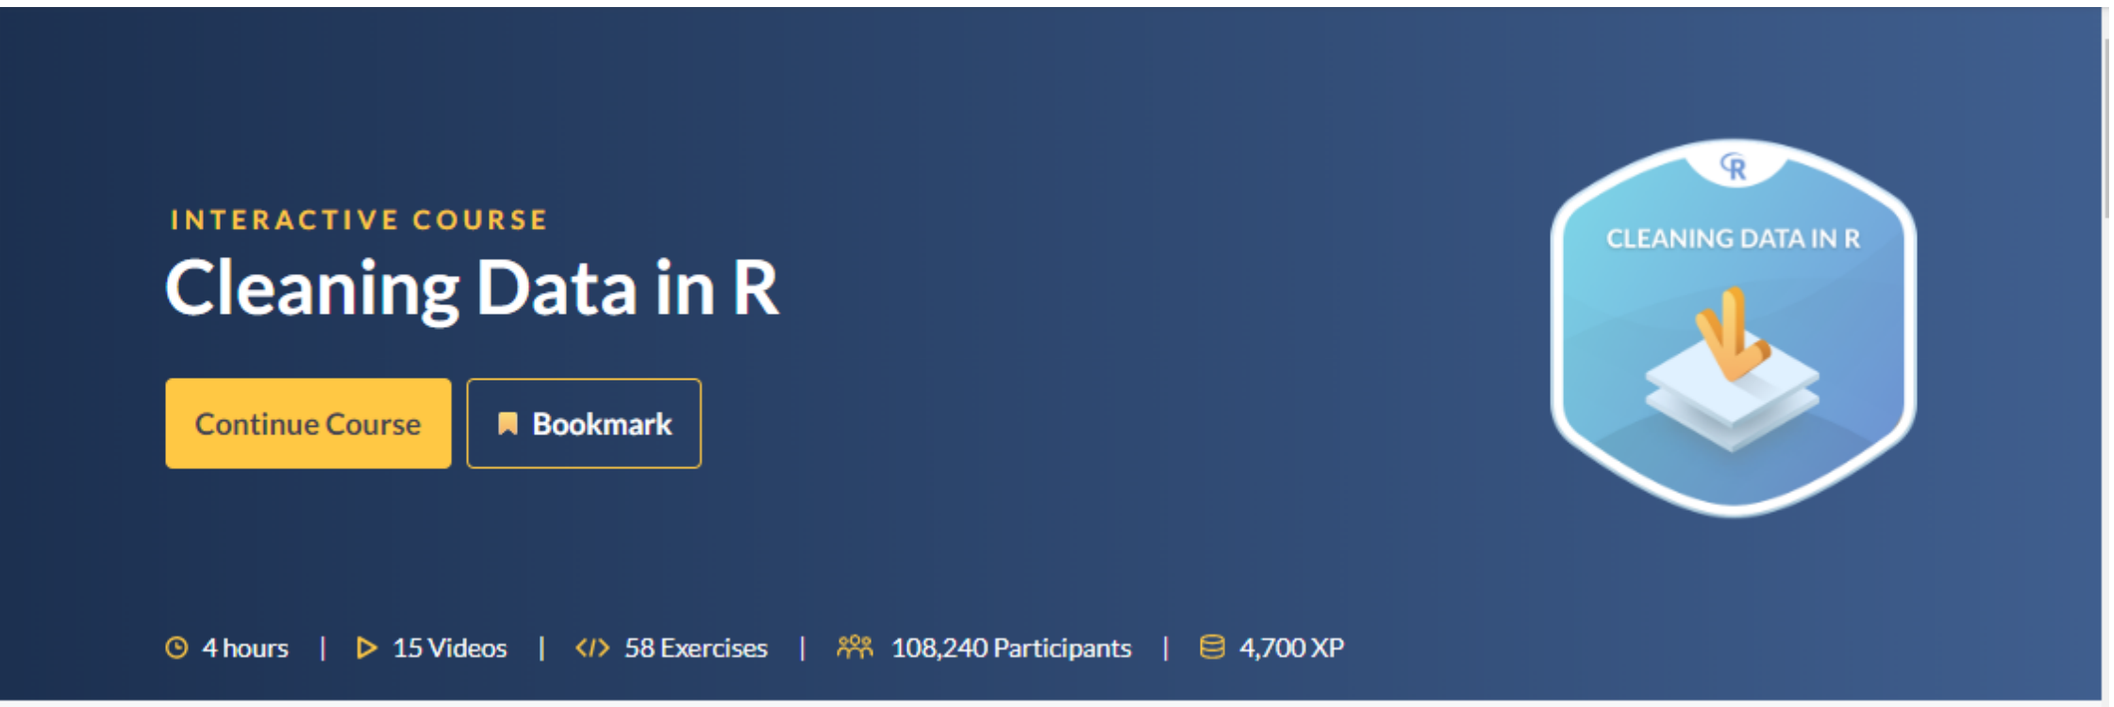

谢谢！

孙惠平

sunhp@ss.pku.edu.cn